CartPole Stabilization – LQR ve PPO Karşılaştırması

Deney Raporu

Osman Melih Muslu

5 Kasım 2026

1 LQR Kontrolcüsü

1.1 Doğrusallaştırılmış model

Durum vektörü ve kontrol girişi

$$\mathbf{x} = \begin{bmatrix} x & \dot{x} & \theta & \dot{\theta} \end{bmatrix}^\top, \qquad u = F \text{ [N]} \tag{1}$$

olarak tanımlanmıştır. Durum vektörü kalın $\mathbf{x}$, araba konumu ise skaler x ile gösterilmektedir. CartPole dinamiği, dik denge noktası $\mathbf{x} = \mathbf{0}$ etrafında doğrusallaştırılarak

$$\dot{\mathbf{x}} = A\mathbf{x} + Bu \tag{2}$$

elde edilir. Kullanılan parametrelerle ($M = 1$ kg, $m = 0.1$ kg, $l = 0.5$ m, $g = 9.8$ m/s^2)

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & -0.717 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 15.776 & 0 \end{bmatrix}, \qquad B = \begin{bmatrix} 0 \\ 0.976 \\ 0 \\ -1.463 \end{bmatrix} \tag{3}$$

bulunur. A matrisinin özdeğerleri $\{-3.97,\ 0,\ 0,\ +3.97\}$'tür; $+3.97$ özdeğeri dik konumun açık çevrimde kararsız olduğunu gösterir. Model, simülatörün kendi sembolik modelinden (safe-control-gym, CasADi) alınmaktadır.

1.2 Discretization

Kontrolcü $f_c = 15$ Hz ile çalıştığından ($\Delta t = 1/15$ s) ve kuvvet bir kontrol periyodu boyunca sabit tutulduğundan, model zero-order hold (ZOH) ile tam olarak ayrıklaştırılmıştır:

$$\mathbf{x}_{k+1} = A_d\mathbf{x}_k + B_d u_k, \qquad A_d = e^{A\Delta t}, \qquad B_d = \int_0^{\Delta t} e^{A\tau}\, d\tau\, B. \tag{4}$$

1.3 Optimal kontrol problemi

LQR, infinite horizon quadratic cost u minimize eden optimal state-feedback i bulmaya çalışır:

$$J = \sum_{k=0}^{\infty} \left(\mathbf{x}_k^\top Q\, \mathbf{x}_k + R\, u_k^2 \right), \qquad Q = \mathrm{diag}(q_x, q_{\dot{x}}, q_\theta, q_{\dot{\theta}}). \tag{5}$$

Q durum hatalarını, R ise kontrol eforunu cezalandırır.

Çözüm, discrete time Riccati denkleminin (DARE) pozitif tanımlı çözümü P ile verilir:

$$P = A_d^\top P A_d - A_d^\top P B_d \left(R + B_d^\top P B_d \right)^{-1} B_d^\top P A_d + Q. \tag{6}$$

Optimal kontrol yasası doğrusal durum geri beslemesidir:

$$u_k = -K \mathbf{x}_k, \qquad K = \left(R + B_d^\top P B_d \right)^{-1} B_d^\top P A_d. \tag{7}$$

Doğrusal modelde, $\mathbf{x}_0$ başlangıç durumundan itibaren elde edilecek toplam maliyet önceden bilinir:

$$J^*(\mathbf{x}_0) = \mathbf{x}_0^\top P\, \mathbf{x}_0. \tag{8}$$

1.4 Bu çalışmadaki LQR

$Q = \mathrm{diag}(1, 1, 1, 1)$ ve $R = 0.1$ için

$$K = \begin{bmatrix} -2.064 & -3.880 & -36.413 & -9.537 \end{bmatrix} \tag{9}$$

elde edilmiştir. Kapalı çevrim kutupları $s = -1.08,\ -2.24 \pm 0.86j,\ -7.24$ olup sistem kararlıdır. Örnek olarak $\mathbf{x}_0 = (-1,\ 0,\ 10^\circ,\ 0)$ $J^* = 21.56$ verir; simülasyonda ölçülen değer 21.63'tür. Aradaki küçük fark, gerçek sistemin doğrusal olmamasından ve sonlu (10 s) horizondan kaynaklanır.

1.5 Sürtünme ileri beslemesi (LQR+FC)

Cart Coulomb sürtünmesinin tahmini $\hat{F}_c$ biliniyorsa LQR'a ileri besleme terimi eklenir:

$$u_k = -K \mathbf{x}_k + \hat{F}_c \tanh\!\left(\frac{\dot{x}_k}{\varepsilon} \right), \qquad \varepsilon = 0.01 \text{ m/s}. \tag{10}$$

Bu terim, sürtünmenin kontrol girişiyle aynı kanaldan girmesi sayesinde doğrudan iptal edilebilir.

2 Ortak Deney Düzeni

2.1 Sistem ve simülasyon

Parametre	Değer
Simülatör	safe-control-gym CartPole (PyBullet)
Araba kütlesi M	1.0 kg
Çubuk kütlesi m	0.1 kg
Çubuk uzunluk parametresi l	0.5 m
Fizik frekansı	750 Hz
Kontrol frekansı	15 Hz ($\Delta t = 0.0667$ s)
Bölüm süresi	10 s (150 kontrol adımı)
Kuvvet sınırı	± 10 N
Bölüm sonlanması	eğitimde $\lvert x\rvert > 2.4$ m veya $\lvert\theta\rvert > 90°$; değerlendirmede bölüm her zaman 10 s sürer

Tablo 1: Sistem ve simülasyon parametreleri (tüm deneylerde ortak).

2.2 Karşılaştırma ölçütü

İki kontrolcü aynı karesel maliyetle değerlendirilmiştir:

$$J = \sum_{k=0}^{149} \left(\mathbf{e}_k^\top Q\, \mathbf{e}_k + R\, F_k^2 \right), \qquad Q = \mathrm{diag}(1,1,1,1), \quad R = 0.1. \tag{11}$$

Burada $\mathbf{e}_k$ referansa göre durum hatası, F_k sisteme gerçekten uygulanan kuvvettir. PPO'nun eğitimde kullandığı ödül aynı ağırlıklarla $r_k = \exp\big(-(\mathbf{e}_k^\top Q\, \mathbf{e}_k + R F_k^2)\big)$ şeklindedir. J küçük olan kontrolcü daha iyidir.

2.3 PPO

Parametre	Değer
Ağ yapısı	actor ve critic, 32 nöronlu gizli katmanlar
γ	0.98
Clip ϵ	0.1
Rollout	$150 \times 4 = 600$ adım
Optimizasyon	5 epoch, mini-batch 128
Değerlendirme	deterministik (actor ortalaması, $a_k = \mu(\mathbf{x}_k)$)

Tablo 2: PPO eğitim parametreleri.

2.4 Kullanılan politikalar

Kısaltma	Klasör (`models/`)	Eğitim koşulu
PPO-nom	`ppo_nominal_seed1_20261103_202300`	sürtünmesiz, $\theta_0 \in \pm 9^\circ$
PPO-fric	`ppo_coulomb1N_20261103_202101`	$F_c = 1$ N, $\theta_0 \in \pm 9^\circ$
PPO-wide	`ppo_wide30_300k_seed1_20261103_204748`	sürtünmesiz, $\theta_0 \in \pm 30^\circ$
PPO-wide-J	`ppo_wide30_1M_lrdecay_jbest_seed1_...`	$\pm 30^\circ$, 1M, LR decay, J-best

Tablo 3: Deneylerde kullanılan PPO politikaları.

3 Deney 1: Nominal Sistem

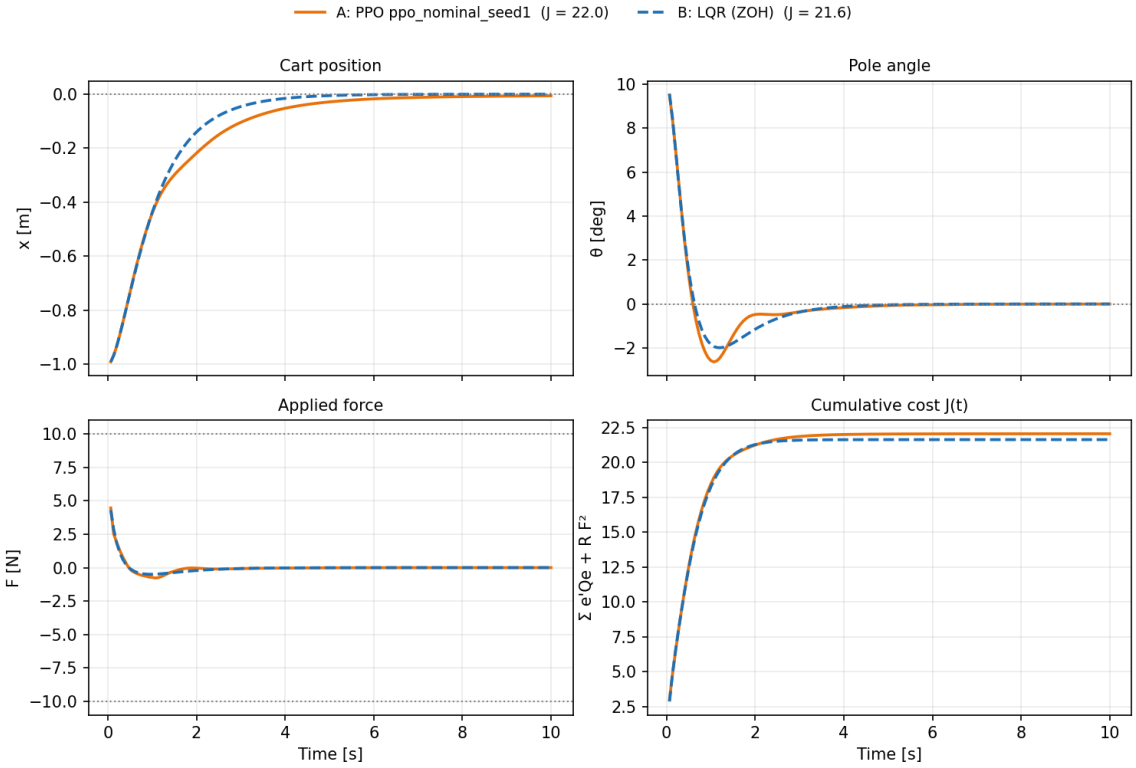
Parametreler.

- Plant: nominal (sürtünmesiz), kuvvet sınırı ± 10 N
- Başlangıç durumu: $x_0 = -1$ m, $\dot{x}_0 = 0$, $\theta_0 = 10^\circ$, $\dot{\theta}_0 = 0$
- Kontrolcüler: LQR (ZOH), PPO-nom
- Gürültü, bozucu, gecikme: yok

Sonuçlar.

Kontrolcü	J	J^* (LQR tahmini)	Maks. $\lvert F\rvert$ [N]	Oturma süresi [s]
LQR	21.63	21.56	4.29	2.93
PPO-nom	22.05	–	4.46	4.13

Tablo 4: Deney 1 sonuçları.



Şekil 1: Deney 1: LQR (mavi) ve PPO-nom (turuncu), nominal sistem, $\theta_0 = 10°$.

Yorum. İki yanıt neredeyse aynıdır; PPO'nun maliyeti LQR'dan yalnızca %2 fazladır. Doğrusal bölgede LQR bu maliyet için optimum olduğundan, PPO'nun bu optimuma yaklaşması eğitim kurulumunun doğru çalıştığını göstermektedir.

4 Deney 2: Cart Coulomb Sürtünmesi

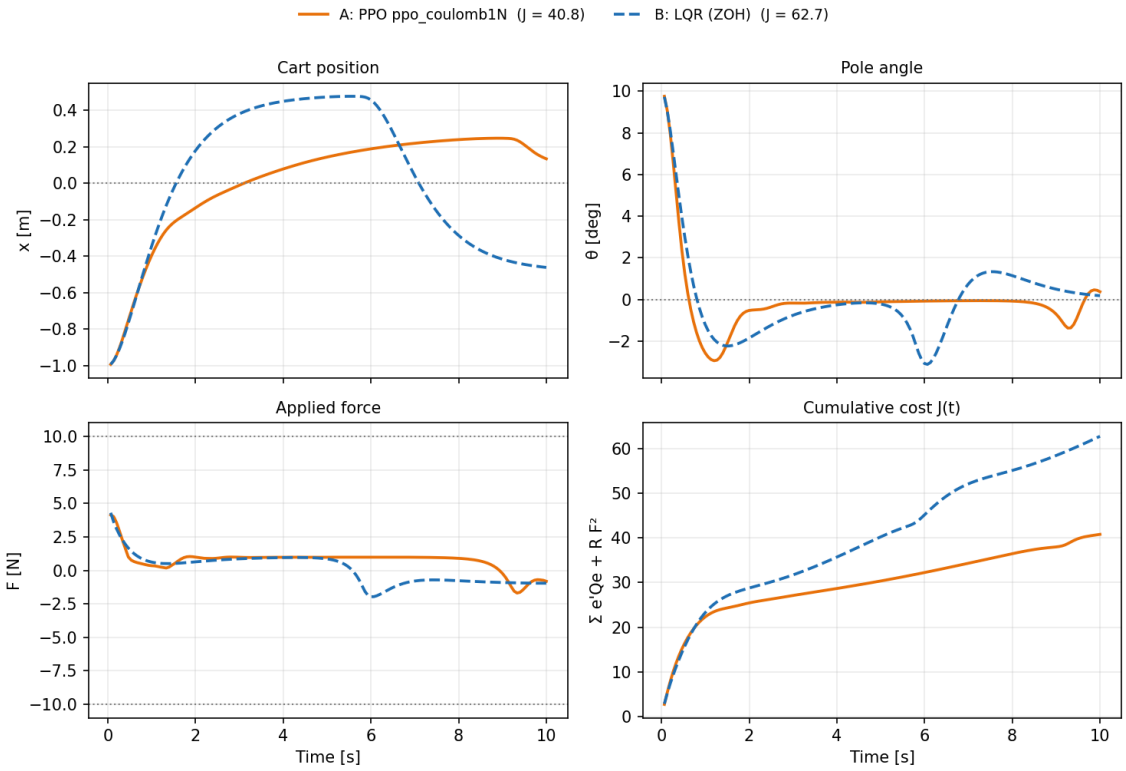
Parametreler.

- Plant: Cart Coulomb sürtünmesi $F_c = 1$ N, kuvvet sınırı ± 10 N
- Başlangıç durumu: $x_0 = -1$ m, $\dot{x}_0 = 0$, $\theta_0 = 10°$, $\dot{\theta}_0 = 0$
- Kontrolcüler: LQR (sürtünmeyi bilmiyor), LQR+FC ($\hat{F}_c = 1$ N), PPO-fric (sürtünmeli sistemde eğitilmiş), PPO-nom (sürtünmesiz eğitilmiş)

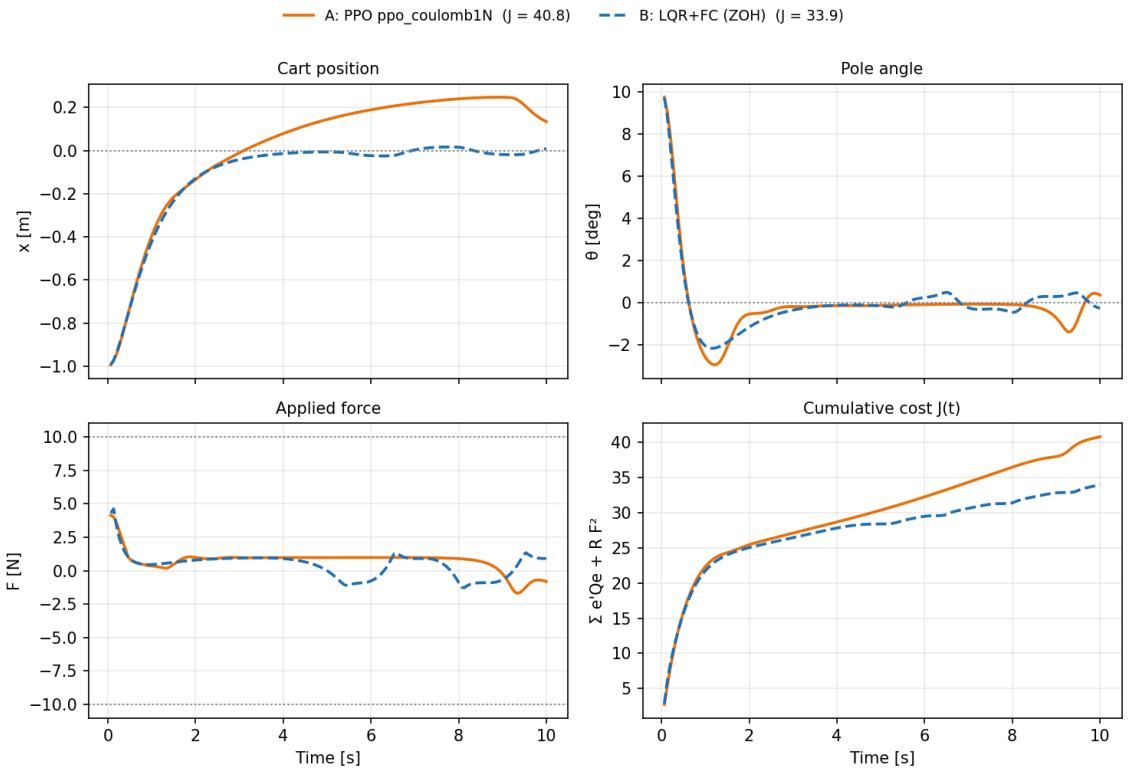
Sonuçlar.

Kontrolcü	J	Hedefe oturdu mu?
LQR	62.73	hayır
LQR+FC ($\hat{F}_c = 1$ N)	33.95	evet (2.87 s)
PPO-fric	40.79	hayır
PPO-nom	44.40	hayır

Tablo 5: Deney 2 sonuçları.



Şekil 2: Deney 2: LQR ve PPO-fric, $F_c = 1$ N. Sürtünmeyi bilmeyen LQR'da araba hedefe oturmuyor ve $J(t)$ sürekli artıyor.



Şekil 3: Deney 2: LQR+FC ve PPO-fric, $F_c = 1$ N.

Yorum. Sürtünme modelde olmadığında LQR'ın maliyeti nominal duruma göre yaklaşık üç katına çıkmaktadır. Sürtünmeli sistemde eğitilen PPO LQR'dan belirgin şekilde iyidir; sürtünmesiz eğitilen PPO da LQR'ı geçmektedir. Ancak sürtünme doğru biliniyorsa ileri beslemeli LQR+FC en iyi sonucu vermektedir.

5 Deney 3: Sürtünme Tahmini Yanlışken

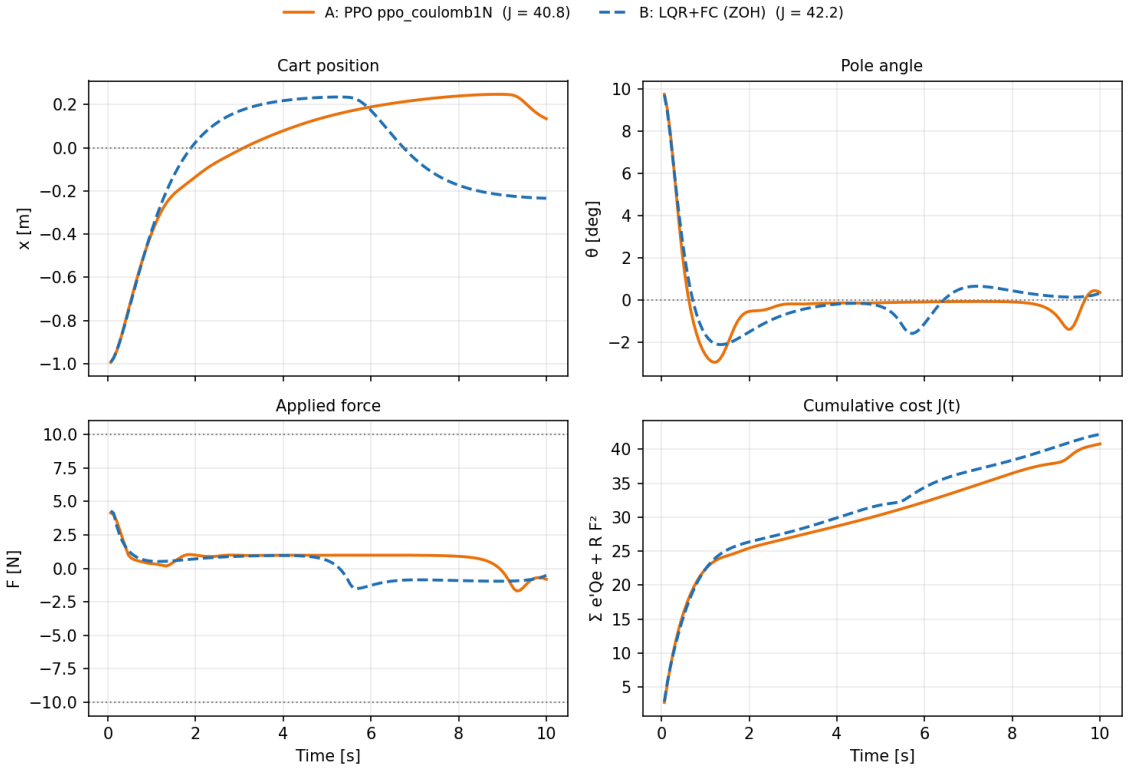
Parametreler.

- Plant: gerçek sürtünme $F_c = 1$ N
- LQR+FC tahmini: $\hat{F}_c = 0.5,\ 1.0,\ 1.5$ N
- Başlangıç durumu ve diğer ayarlar: Deney 2 ile aynı

Sonuçlar.

Kontrolcü	J
LQR+FC, $\hat{F}_c = 0.5$ N	42.20
LQR+FC, $\hat{F}_c = 1.0$ N	33.95
LQR+FC, $\hat{F}_c = 1.5$ N	44.73
PPO-fric	40.79

Tablo 6: Deney 3 sonuçları.



Şekil 4: Deney 3: LQR+FC ($\hat{F}_c = 0.5$ N) ve PPO-fric.

Yorum. Sürtünme %50 hatayla tahmin edildiğinde LQR+FC'nin avantajı kaybolmakta ve PPO-fric daha iyi sonuç vermektedir.

6 Deney 4: Büyük Başlangıç Açıları

Parametreler.

- Plant: nominal, kuvvet sınırı ± 10 N
- Değişen tek büyüklük başlangıç açısıdır: $\theta_0 = 5°, 10°, \ldots, 45°$ ($5°$ adımlarla, 9 değer)
- Diğer başlangıç değerleri her koşuda sıfırdır: konum $x_0 = 0$, hız $\dot{x}_0 = 0$, açısal hız $\dot{\theta}_0 = 0$ (araba ve çubuk durağan, yalnızca çubuk eğik başlar)

- GUI: Experiment sekmesinde $x_0 = 0$, $\dot{x}_0 = 0$, $\dot{\theta}_0 = 0$; θ_0 sweep `5:45:5`
- Kontrolcüler:
  - **LQR**: Bölüm 2'deki ZOH tabanlı LQR ($Q = \mathrm{diag}(1, 1, 1, 1)$, $R = 0.1$).
  - **PPO-wide**: Standart PPO yalnızca $\theta_0 \in \pm 9°$ ile eğitildiğinden, büyük açılarda adil bir karşılaştırma için başlangıç aralığı genişletilerek yeniden eğitilmiştir: $\theta_0 \in \pm 30°$, $x_0 \in \pm 1.5$ m, $\dot{x}_0, \dot{\theta}_0 \in \pm 1$. Sürtünmesiz sistem, 300k adım, sabit öğrenme oranı; en iyi model en yüksek değerlendirme ödülüne göre seçilmiştir.
  - **PPO-wide-J**: PPO-wide ile aynı başlangıç aralığı ve sistem; 1M adım, öğrenme oranı eğitim boyunca başlangıç değerinin %10'una doğrusal olarak azaltılmıştır. En iyi model, her 6000 adımda 8 sabit başlangıç durumunda hesaplanan ortalama J'ye göre seçilmiştir.
- Not: $\theta_0 \geq 15°$'de kuvvet sınırına ulaşılmaktadır; bu deney satürasyonsuz koşulun dışına çıkmaktadır.

Sonuçlar.

θ_0	LQR	PPO-wide	PPO-wide-J
5°	3.7	4.8	3.8
10°	15.0	17.4	15.8
20°	67.3	72.0	68.4
30°	226.4	233.8	228.2
35°	458.5	523.3	474.4
40°	2709.8	düştü	düştü
45°	düştü	düştü	düştü
Yakalanan en büyük açı	40°	35°	35°

Tablo 7: Deney 4 sonuçları (J değerleri).



Şekil 5: Deney 4: θ_0 taraması, J (logaritmik) ve başlangıç açısı. × işareti çubuğun düştüğünü gösterir.

Yorum. LQR, doğrusallaştırmanın geçerlilik bölgesinin oldukça dışında (40°'ye kadar) çubuğu yakalayabilmektedir. PPO ise eğitim aralığının (±30°) biraz ötesine kadar başarılıdır ve her açıda LQR'dan biraz daha yüksek maliyete sahiptir. Doğrusal olmama tek başına PPO'ya avantaj sağlamamaktadır.

7 Deney 5: Eğitim Süresinin Etkisi

Parametreler.

- Eğitim: geniş aralık ($\theta_0 \in \pm 30°$), 3 seed
- Karşılaştırılan eğitim bütçeleri: 300k ve 1M adım; 1M adım + doğrusal learning rate azaltma + J'ye göre en iyi checkpoint seçimi
- Değerlendirme: Deney 4 ile aynı θ_0 taraması

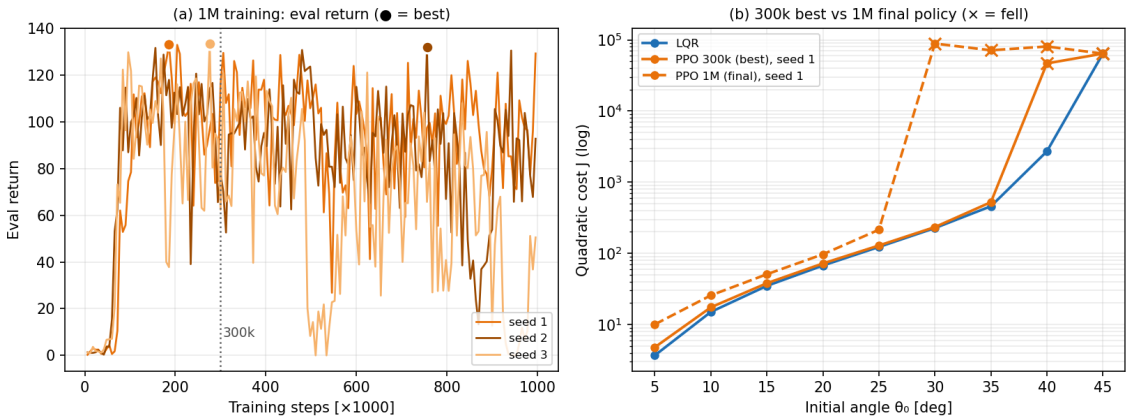
Sonuçlar.

300k ve 1M adım karşılaştırması

Yalnızca eğitim süresinin etkisini görmek için PPO-wide, diğer tüm ayarlar aynı kalacak şekilde 1M adım boyunca da eğitilmiştir (sabit öğrenme oranı, 3 seed). Aynı seed ile eğitim ilk 300k adımda birebir aynı ilerlediğinden, 300k eğitimin en iyi modeli ile 1M eğitimin *sonunda* elde edilen model karşılaştırılmıştır.

	Yakalanan en büyük θ_0		J ($\theta_0 = 10°$)		J ($\theta_0 = 20°$)	
Seed	300k	1M	300k	1M	300k	1M
1	35°	25°	17.4	25.6	72.0	96.9
2	30°	25°	15.7	27.6	70.8	118.7
3	25°	25°	15.4	67.9	74.4	142.3
LQR	40°		15.0		67.3	

Tablo 8: 300k adımda seçilen en iyi model ile 1M adım eğitimin son modeli (Deney 4 ile aynı θ_0 taraması, $x_0 = \dot{x}_0 = \dot{\theta}_0 = 0$).

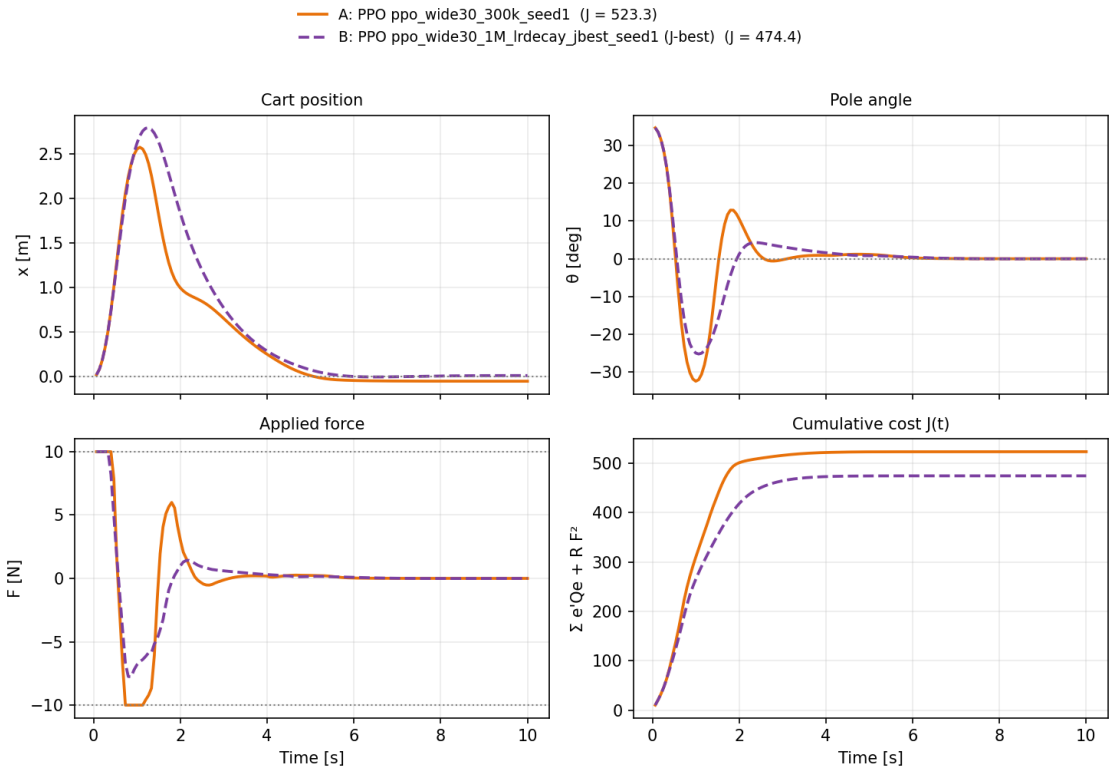


Şekil 6: (a) 1M adım eğitim boyunca değerlendirme ödülü; • her seed'in en iyi modelini gösterir. (b) Seed 1 için 300k en iyi model ile 1M son model, θ_0 taraması.

Eğitim ödülü yaklaşık 100k adımda doyuma ulaşmakta, sonrasında ise iyileşmeden dalgalanmaktadır (Şekil a). Seed 1 ve 3'te en yüksek ödüllü model 300k adımdan önce bulunmuş ve sonraki 700k adımda geçilememiştir; bu nedenle bu seed'lerde 1M eğitimin dosyası 300k eğitimininkiyle

aynıdır. Eğitim sonunda kalan politika ise her üç seed'de de 300k'nın en iyi modelinden daha kötüdür: $\theta_0 = 10°$'de maliyet %47–341 artmış, yakalanan en büyük açı 25°'ye düşmüştür. Dolayısıyla sabit öğrenme oranıyla eğitimi uzatmak politikayı iyileştirmemekte, aksine bozabilmektedir.

1M adım, 300k adıma göre iyileşme sağlamamıştır; eğitim ilerledikçe değerlendirme ödülü düşmüştür. Öğrenme oranının doğrusal azaltılması ve en iyi politikanın RL ödülü yerine J'ye göre seçilmesiyle bu çöküş giderilmiş ve yakalama sınırı 30–35°'ye çıkmıştır.



Şekil 7: Deney 5: PPO-wide (300k) ve PPO-wide-J (1M, LR decay, J-best).

Yorum. Daha uzun eğitim tek başına daha iyi politika anlamına gelmemektedir. PPO'nun eğitimde maksimize ettiği ödül (indirgenmiş exp(c) toplamı) ile karşılaştırmada kullanılan J aynı değildir. Örneğin exp fonksiyonu büyük hataları doyurduğu için ödül, kısa süreli büyük sapmaları J'ye göre çok daha az cezalandırır. Bu nedenle eğitim sırasında kaydedilen modeller arasından hangisinin 'en iyi' seçildiği, kullanılan ölçüte bağlıdır ve raporlanan J değerini doğrudan etkiler.

Not. $\theta_0 = 35°$'de her iki politikada da araba $x \approx 2.6$–2.8 m'ye kadar gitmektedir. Bu, eğitimde bölümü bitiren $|x| = 2.4$ m sınırının ötesidir; değerlendirmede bölüm sonlandırılmadığı için çubuk yine de yakalanmaktadır. Gerçek sistemde ray uzunluğu bu yanıtı sınırlayacaktır.

8 Sonuç

- Aynı maliyet fonksiyonu altında ve model biliniyorken LQR, PPO'dan daha iyidir; PPO bu optimuma yaklaşmaktadır.

- Modelde bulunmayan sürtünme LQR'ın performansını belirgin şekilde düşürmektedir; bu durumda PPO daha iyidir.
- Sürtünme doğru biliniyorsa ileri beslemeli LQR en iyi sonucu verir; tahmin hatalı olduğunda avantaj PPO'ya geçer.
- Büyük açılarda LQR beklenenden sağlamdır; PPO eğitim aralığının dışına genelleme yapamamaktadır.
- Daha uzun eğitim tek başına iyileşme sağlamamaktadır.